

Compression huffman:

Le premier choix important fut le choix de la structure de donnée permettant de créer un arbre pratique . La liste était un choix tout trouvé car elle permettrait une flexibilité du nombre de donnée contenu en son sein mais aussi un accès pratique à ses éléments une fois déplié en arbre . En effet , les liens de la liste si nous les faisons subsister permettent un parcour en largeur de l'arbre .

Le deuxième choix important fut le choix des données contenu dans la cellule (maillon de l'arbre) , pour n'exclure aucune langue nous avons opté pour un int . Il est certes plus lourd mais il fait la taille d'un mot en machine donc les opérations sont facilement optimisables (à nuancer tout de même en fonction de l'architecture de la machine concerné) .De plus , il est utilisé pour stocker le nombre de feuilles des nodes , ce qui rend la profondeur casi infini et donc le nombre de caractère différents maximum de 4,3 M

(à nuancer sur la version présenté du projet car les "bitwise operator " n'étant pas sécurisés il se pourrait qu'il y est des bugs une fois la profondeur supérieure à 32)

Le troisième choix fut comment structurer le corps d'une cellule dans l'entête du fichier . En marquant successivement le nombre des feuilles des parents de la feuille considéré l'accès à cette dernière l'ors de la décompression est très rapide . Bien qu'ils représentent une (faible) perte du potentiel de compression ils permettent d'accéder rapidement au binaire lu l'ors de la décompression ce qui dans des fichiers avec énormément de char peut être utile .

Le code ici présenté est une version de démonstration car elle n'est pas réellement une compression mais juste une vision en "clair" du mécanisme . Ce projet devait s'effectuer en plusieurs temps :

- le premier est la création de cette version de test ,destiné à présenter le projet (dans le cadre d'une utilisation normale et peu poussé)mais aussi débbugger facilement la seconde version .Son autre but est d'être plus performante en terme de temps qu'en terme " d'espace " .Son inconvénient est qu'il ne fait que très peu cas des opérations sur les bits car les cas échéant n'arrive que très rarement . Cela dit grâce au code de la seconde version ce rare défaut peut être facilement corriger .

- le second est une réelle implémentation de la compression : en limitant au maximum la taille du fichier une fois compressé (système de suffixe ,de concaténation d'int ,...).La version 2 porte son intérêt sur la place occupé par le fichier compressé et sur une gestion optimal des bits de manière sécurisé .Contrairement à la version 1 le cas ou la pronfondeur venait à dépasser 32 est parfaitement gérer sans perte .

- et le troisième est un mixe des 2 avec les avantages de la version test comme faciliter l'accès l'ors de la décompression et les avantages de la version 2 : la sécurité et le gain de place .En effet , la compression de la version 1 marche car notre IDE cast implicitement les int en long int , en long long int ... si nous dépassons 32 bits . Le

fait que la profondeur dépasse 32 n'est pas vraiment prévue par le code ainsi des problèmes pourraient survenir suivant la machine employé.

Ainsi il est nécessaire de croiser les 2 versions qui sont complémentaire :

Le système de suffixe est très performant pour économiser de la place mais il est très coûteux en terme performance c'est pour cela que nous comptons y intégrer l'accès rapide des feuilles lors de la décompression (de la version 1) qui est un peu coûteux en données mais qui fait gagner beaucoup de temps .

Le projet final n'ayant pas abouti à temps nous n'avons qu'une compression didactique à présenter et une ébauche de la compression dans son ensemble .Mais nous sommes à même de répondre aux potentielles questions sur ces 2 versions . Leur unicité symboliser par le troisième projet n'ayant pas été commencé nous ne pouvons que spéculer sur sa future implémentation .